

Machine Learning e Inferencia Bayesiana / Matemáticas Aplicadas a la Ciencia de Datos

Integrantes del Equipo:

- Fátima Sofía García de León Torres
- Miguel Angel Magaña Solís
- Sophia Díaz de León Gleason
- Kevin Uziel García Márquez

1. Introducción y planteamiento del problema

Descripción general: El presente proyecto aborda la relación existente entre los hábitos de vida de los estudiantes universitarios y su rendimiento académico. El comportamiento diario, la gestión del tiempo y la salud mental son componentes integrales que moldean la trayectoria académica de un individuo.

Objetivo del proyecto: Analizar factores como horas de estudio, duración del sueño, tiempo frente a pantallas, actividad física, asistencia y niveles de estrés, con el fin de entrenar modelos predictivos de Machine Learning que estimen tanto el promedio de calificaciones (CGPA) como las notas parciales (Internal Marks), así como clasificar el éxito académico.

Justificación: Los modelos de Inteligencia Artificial dependen completamente de la calidad de los datos. Analizar el estilo de vida de los alumnos demuestra que mantener un historial estructurado de actividades cotidianas permite generar predicciones valiosas. Encontrar factores determinantes que influyan en el rendimiento permite implementar estrategias de apoyo estudiantil personalizadas.

2. Descripción de los datos

Fuente de datos: Se utilizó el conjunto "Student Lifestyle and Academic Performance Dataset" extraído de la plataforma Kaggle, el cual contiene datos generados sintéticamente que simulan características reales de 1000 estudiantes.

Descripción de variables: El dataset se compone de 12 columnas. Combina variables numéricas continuas y discretas (como *Age*, *Study_Hours_per_Day*, *Sleep_Hours*, *Screen_Time_Hours*, *Gym_Hours_per_Week*, *Attendance_Percentage*, *Stress_Level_1_to_10*, *Internal_Marks* y *CGPA*) con variables categóricas nominales (como *Branch*, *Diet_Type*, y *Residence*).

Tipos de problema planteados:

- **Regresión:** Predicción continua del Promedio General (CGPA) y las calificaciones internas.
- **Clasificación:** Mediante la creación de una variable derivada *pass* (1 si *Internal_Marks* $\geq$ 60, 0 en caso contrario) para evaluar la probabilidad de aprobación.

3. Limpieza y preparación de datos

Se verificó la integridad de la base de datos, obteniendo 0 valores nulos y 0 registros duplicados, garantizando un punto de partida estable, esto debido a que son datos generados sintéticamente, por lo que los datos están completamente limpios. Para el manejo de las variables categóricas nominales (*Branch*, *Diet_Type*, *Residence*), se implementó un traductor utilizando *OneHotEncoder* configurado con *handle_unknown="ignore"*, lo que evita fallos en producción si la API recibe datos no vistos. Esto se integró directamente en un *ColumnTransformer*, dejando el resto de variables numéricas sin alterar mediante el argumento *remainder="passthrough"*. Se consolidó este preprocesamiento dentro de un Pipeline de Scikit-Learn exportado en un archivo .pkl, asegurando que cualquier entrada de datos nueva, como las recibidas a través de peticiones HTTP, pase por el mismo proceso de estandarización sin fugas de información.

4. Análisis exploratorio (Probabilidad y Estadística)

Para comprender estadísticamente la distribución poblacional, se aplicaron pruebas rigurosas de inferencia estadística clásica:

Prueba T-Student Pareada: Se evaluó la diferencia de medias entre *Study_Hours_per_Day* y *Screen_Time_Hours*. El Estadístico T experimental fue de -11.9626, muy superior en magnitud al valor crítico de la tabla (1.9623). *Conclusión:* Se rechaza la hipótesis nula (H_0). Existe un desbalance de tiempo significativo (los estudiantes pasan más tiempo en pantalla que estudiando), lo cual afectará fuertemente los pesos en la regresión.

Análisis de Varianza (ANOVA): Se examinó el impacto de *Stress_Level* (agrupado en Bajo, Medio, Alto) sobre el *CGPA*. Los resultados arrojaron una Suma de Cuadrados de Tratamientos (SSA) de 29.24 y del Error (SSE) de 879.60, con un Estadístico F de 16.5752 frente a un valor crítico de 3.0048. *Conclusión:* Se rechaza la H_0 . El estrés altera críticamente las medias de calificación, confirmándolo como un predictor de alto impacto.

5. Modelado de Machine Learning

Se probaron cuatro algoritmos fundamentales, abordando diferentes perspectivas geométricas e inferenciales:

- **Regresión Lineal Múltiple:** Modelo paramétrico clásico. Se justificó su uso por su convexidad matemática, garantizando un óptimo global. Se evaluó mediante el Error Cuadrático Medio (MSE) y R^2 para determinar la varianza explicada. Resulta ideal para establecer relaciones lineales directas (e.g. Asistencia vs CGPA).
- **Regresión Logística:** Adaptado para la tarea de *clasificación* al binarizar el objetivo en aprobado/reprobado. Se evaluó con matrices de confusión, Curva ROC, AUC, Precisión y Exhaustividad (Recall). Resultó excelente para emitir probabilidades directas de que un alumno pase sus materias.
- **Support Vector Machine para Regresión (SVR):** Modelo robusto ante outliers mediante la utilización de un margen de tolerancia ϵ . A través del *kernel trick*, proyecta los datos a espacios hiperdimensionales, logrando capturar relaciones fuertemente no lineales, como el pico de estrés y la caída del rendimiento, que un modelo lineal puro ignoraría.
- **Árboles de Decisión:** Modelo no paramétrico que fragmenta el espacio de características mediante hiperplanos ortogonales a los ejes. Su uso se justificó para identificar reglas jerárquicas lógicas (ej. *Si asistencia < 60% y estrés > 8, entonces CGPA = Bajo*). Se controló su profundidad máxima para evitar el

sobreajuste (overfitting).

6. Comparación y selección de modelos

La evaluación comparativa arrojó matices cruciales:

Modelo	Interpretabilidad	Complejidad / Tiempo	Comportamiento / Robustez
Regresión Lineal	Alta (Pesos directos)	Muy rápido ($O(nd^2)$)	Sensible a la multicolinealidad y outliers.
Regresión Logística	Alta (Odds ratios)	Rápido	Estable para clasificación probabilística.
SVR	Baja (Caja negra)	Lento en entrenamiento	Altamente robusto en fronteras complejas.
Árboles de Decisión	Muy Alta (Estructura visual)	Rápido inferencialmente	Propenso al sobreajuste sin poda adecuada.

Selección Final: Se optó por priorizar el **Pipeline de Regresión Lineal** para presentar ya que consideramos que no necesitábamos de un modelo tan complejo al tener datos muy simples, a su vez fué el modelo que nos dió mejores métricas y precisión, quitando regresión logística ya que dió métricas más altas, sin embargo nos pareció más interesante predecir la calificación numérica que simplemente pasa o no pasa, también nos permitió su despliegue y latencia en backend es mínima, permitiendo que la API construida con FastAPI y MongoDB Atlas (Base de datos NoSQL) devuelva predicciones en tiempo real y sea sumamente transparente para las decisiones académicas.

7. Desarrollo matemático y fundamentos teóricos

7.1. Regresión Lineal y Complejidad Computacional

La formulación matemática de la regresión múltiple busca encontrar el vector de parámetros β que minimice la Función de Costo (Mean Squared Error). Esto se expresa algebraicamente como el ajuste del hiperplano: $y = X\beta + \varepsilon$.

En un enfoque teórico manual (Ecuación Normal), los pesos se obtienen calculando la matriz pseudoinversa: $\beta = (X^T X)^{-1} X^T y$.

Análisis de Complejidad Computacional: Implementar manualmente el algoritmo de la Ecuación Normal implica invertir una matriz, lo cual tiene una complejidad cúbica $O(d^3)$ respecto a las características. Según nuestras pruebas documentadas, aunque operar con 1000 registros es rápido, escalar a 500,000 registros colapsa implementaciones ingenuas. Scikit-Learn, por el contrario, emplea Factorización QR o Descomposición en Valores Singulares (SVD) acoplados con álgebra lineal a bajo nivel (BLAS/LAPACK) para encontrar la Pseudoinversa de Moore-Penrose. Esto prioriza la estabilidad numérica y evita que la matriz explote por multicolinealidad, aunque exija mayor tiempo computacional comparado a la fuerza bruta.

Supuestos y Multicolinealidad: Para que este modelo mantenga sus propiedades teóricas (ser el Mejor Estimador Lineal Insesgado, BLUE), se vigiló rigurosamente la multicolinealidad. Variables como *Attendance_Percentage* e *Internal_Marks* pueden inflar la varianza, por lo que es mandatorio calcular el *Factor de Inflación de Varianza (VIF)* para evitar signos contraintuitivos en los coeficientes β .

7.2. Regresión Logística (Inferencia Bayesiana Clásica)

Para estimar la probabilidad p de que un estudiante apruebe, se utiliza la función sigmoide que comprime la salida lineal entre 0 y 1:

$$p = 1 / (1 + e^{-(X\beta)})$$

La función de costo empleada no es el MSE (ya que no generaría una función convexa), sino la **Entropía Cruzada (Log-Loss)** derivada del método de Estimación de Máxima Verosimilitud (MLE). Matemáticamente penaliza fuertemente al modelo cuando pronostica que un alumno pasará ($p=0.99$) y en la realidad reprueba ($y=0$). Esta naturaleza probabilística permite no solo predecir etiquetas duras, sino evaluar el grado

de riesgo académico exacto que posee un perfil de estilo de vida.

8. Integración de Infraestructura y Bases de Datos

Aprender a diseñar infraestructuras estables es un requisito obligatorio. Por ello, el modelo serializado `model_pipeline.pkl` se integró en un ecosistema backend utilizando el framework **FastAPI** en Python. Se implementó una base de datos **NoSQL MongoDB Atlas** en la nube (Document DocumentDB) donde los registros de los alumnos y sus predicciones se almacenan y consultan de forma dinámica y también conectado a un servidor en línea Render que nos permitió desplegar todo el backend y frontend, y por último utilizando el dominio de github para que cualquier persona pueda visualizar nuestros resultados usando el modelo de machine learning. Esto demuestra cómo la ciencia de datos transita desde el análisis estático hacia productos de software escalables orientados a servicios (APIs).

9. Resultados y discusión

Interpretación: Se observó que las características modificables, especialmente la relación horas de estudio vs tiempo de pantalla, así como los niveles de estrés detectados mediante ANOVA, tienen una influencia causal teórica sobre el Internal Marks. Los modelos lograron explicar una porción considerable de la varianza en el rendimiento de los alumnos. El pipeline transformó las características cualitativas (como dieta y tipo de residencia) eficientemente, comprobando que quienes radican en ciertos esquemas tienen patrones de sueño y estrés diferenciados.

Fuentes de error: Dado que el dataset es sintético, las distribuciones pueden carecer de la volatilidad estocástica propia del comportamiento humano impredecible, induciendo a métricas de validación ligeramente sobre-optimistas.

10. Conclusiones y trabajo futuro

Hallazgos: La principal revelación radica en la posibilidad real de anticipar el fracaso escolar mediante el monitoreo de variables conductuales extra-académicas. El proyecto validó exitosamente cómo técnicas probabilísticas (ANOVA, T-Student) guían la arquitectura posterior de Modelos de Machine Learning altamente convexos y estables

(Scikit-Learn BLAS/LAPACK).

Limitaciones y Trabajo Futuro: En líneas de investigación posteriores, es mandatorio transitar de un dataset ficticio de Kaggle hacia la obtención de datos vivos mediante encuestas departamentales de la universidad, almacenando series temporales en bases SQL o en la instancia actual de MongoDB. Adicionalmente, se planea fortalecer el desarrollo de la API añadiendo asincronía avanzada para soportar múltiples inferencias simultáneas.

11. Referencias

- Rafi003. (2026). Student Lifestyle and Academic Performance Dataset. Kaggle. Recuperado de: <https://www.kaggle.com/datasets/rafi003/student-lifestyle-and-academic-performance-dataset>.
- Toledano Juárez, I. A. (2025). Tema 4. Regresión lineal: Datos ficticios [Notebook de Jupyter]. Material de clase del curso Machine Learning e Inferencia Bayesiana.
- Toledano Juárez, I. A. (2025). Tema 4. Regresión lineal: simple y múltiple [Notebook de Jupyter]. Material de clase del curso Machine Learning e Inferencia Bayesiana.
- Documentación Oficial Scikit-Learn: Algoritmos lineales, optimizaciones por SVD y QR.
- Documentación FastAPI y PyMongo: Despliegue de APIs y Bases de Datos NoSQL en Python.